

可解释人工智能

最新技术方向 主要应用场景

报告人：王浩权

指导老师：向广利 教授

目录

01. 技术背景

02. 可学习理论

03. 最新技术方向

04. 主要应用场景

01

技术背景

技术背景

“黑盒”模型在安全性、公平性及合规性上面临挑战

01. 解释模型犯错的原因并提高其稳定性

02. 检查模型决策是否依赖于不恰当的特征

03. 法规赋予了用户获得自动化决策解释的权利

02

可学习理论

可学习理论

- 01. 心智理论 (ToM): 研究模型如何匹配人类的认知与理解习惯**
- 02. 信息瓶颈理论: 通过量化特征压缩与保留, 寻找解释的最优解**
- 03. 可解释性度量: 基于保真度、稀疏性和鲁棒性建立数学评估指标**

可学习理论

心智理论 (ToM): 最小化机器与人类之间的认知距离

$\text{Align_ToM}(\text{Model}, \text{Human}) = \text{Minimize}(\text{Distance}(P_{\text{model}}(y|x), P_{\text{human}}(y|x_{\text{exp}})))$

$P_{\text{model}}(y|x)$: 黑盒模型对原始数据 x 预测出结果 y 的机器内部逻辑

$P_{\text{human}}(y|x_{\text{exp}})$: 人类专家在看到模型给出的解释线索 x_{exp} 之后, 在自身心智模型中建立的理解概率分布

$\text{Minimize}(\text{Distance})$: 最小化两者的认知距离, 使机器的解释真正匹配人类的思维习惯

可学习理论

信息瓶颈理论：通过损失函数来平衡信息压缩度与预测相关性

$$\text{Loss_IB} = I(X; Z) - \text{beta} * I(Y; Z)$$

X, Y：原始输入特征向量与模型最终的目标预测标签

Standard_Z：提炼出来的核心解释变量集合（即压缩后的信息特征图）

$I(X; Z)$ ：输入与解释之间的互信息（Mutual Information），代表信息压缩度。该值越小，说明解释越精简

可学习理论

可解释性度量：

局部保真度：统计有多少个样本的预测被成功复刻

$$\text{Fidelity}(g) = (1 / N) * \text{sum_i}(\text{Indicator}(\text{argmax}(f(z_i)) == \text{argmax}(g(z_i)))))$$

$f(z_i)$ ：原黑盒模型（如复杂神经网络）对第 i 个扰动样本 z_i 输出的预测概率向量

$g(z_i)$ ：可解释代理模型（如 LIME 训练的线性模型）对同一个扰动样本 z_i 输出的预测概率向量

$\text{sum_i}(\dots)$ ：对局部邻域内的所有样本（从第 1 个到第 N 个）进行求和，统计出到底有多少个样本的预测被成功复刻

可学习理论

可解释性度量：

稀疏性：特征权重矩阵中，数值不等于零的特征个数

$$\text{Sparsity}(g) = 1 - (\text{Count_NonZero}(W_g) / \text{Total_Features})$$

W_g ：解释模型在生成结论时所计算出来的特征权重或归因值矩阵（比如各个特征的 LIME 回归系数，或者 SHAP 值向量）

$\text{Count_NonZero}(W_g)$ ：非零元素计数函数（在数学上对应 L0 范数）。用来统计特征权重矩阵 W_g 中，其数值不等于 0 的特征个数。只有权重不为 0 的特征，才是真正对最终决策起到解释器作用的“核心有效特征”

可学习理论

可解释性度量：

鲁棒性/稳定性： 计算输入发生微观物理变化后，解释结论本身改变了多少

$$\text{Robustness}(x) = \text{Max}_z(\text{Norm}(\text{Phi}(x) - \text{Phi}(z)) / \text{Norm}(x - z)) \text{ where } ||x - z|| \leq \text{epsilon}$$

$\text{Norm}(x - z)$ ：输入数据实际发生的微观物理变化量

$\text{Norm}(\text{Phi}(x) - \text{Phi}(z))$ ：计算两个解释向量之间的数学距离（通常采用 L2 范数），即输入发生扰动后，解释结论本身改变了多少

03

最新技术方向

最新技术方向

基本算法

LIME 算法

在预测样本周围进行局部扰动，训练线性代理模型进行解释

SHAP 算法

基于合作博弈论的沙普利值，实现特征贡献度的唯一公理化分配

最新技术方向（LIME 算法）

场景：基于 XGBoost 的黑盒贷款审批预测

对象（申请人）：24岁，月入6500元，信用卡负债4.5万元，历史逾期0次

黑盒输出：拒绝贷款（高风险概率 85%）

最新技术方向（LIME 算法）

LIME 局部解释动态生成：

01. 扰动采样：在申请人特征周围加入高斯噪声，生成 5000 个虚拟局部样本

示例样本1：25岁，月入6400，负债4.6万，逾期0次，丢进黑盒模型得到预测 0.83（高风险）

示例样本2：24岁，月入12000，负债1.2万，逾期0次，丢进黑盒模型得到预测 0.12（低风险）

最新技术方向（LIME 算法）

LIME 局部解释动态生成：

02. 邻域加权：用指数核函数计算距离，距离申请人越近的样本，相似度权重越大

计算这些扰动样本与申请人的欧氏距离，距离越近，其相似度权重越大

样本1的权重很高（0.95），样本2因为月入激增，距离很远，权重极低（0.05）

最新技术方向（LIME 算法）

LIME 局部解释动态生成：

03. 代理拟合：以黑盒预测为标签，训练稀疏线性回归模型，局部近似非线性黑盒

利用这 5000 个扰动样本作为训练集，以黑盒预测输出为标签（y轴），以接近度为样本加权，训练一个简单的线性回归回归器。通过限制特征数量，只保留 2~3 个最核心特征

最新技术方向（LIME 算法）

LIME 局部解释动态生成：

04. 系数提取：求解局部线性回归系数，量化核心特征的边际贡献

决策方程： $\Delta_{\text{Risk}} = +45\% * \text{Debt} + 15\% * \text{Age} - 5\% * \text{Income}$

最新技术方向（LIME 算法）

结论：拒贷首要原因为信用卡负债过高（拉高风险 45%）；其次为年龄较小（拉高风险 15%）；月收入虽有正面作用（拉低风险 5%），但无法抵消高负债冲击

最新技术方向（SHAP 算法）

场景：多模态神经网络实时预测急性心力衰竭风险

对象（病人）：心率 115（偏高）、血压 90/60（偏低）、血氧 96%（正常）

黑盒输出：全院基准期望值20%，模型最终高危预测值70%

最新技术方向（SHAP 算法）

Shapley 博弈论分配：

01. 没有任何基础特征（空集）时加入心率

模型仅知道“心率=115”时预测风险为 35%。相比基准 20%，边际贡献为：+15%

最新技术方向 (SHAP 算法)

Shapley 博弈论分配:

02. 在已有“血压=90”的子集 {B} 中加入心率

在低血压背景下，正常预测风险为 45%。此时一旦叠加“心率=115”，两项异常指标引发极度高危，模型输出心衰风险激增至 65%。此时心率的边际贡献为： $65\% - 45\% = +20\%$

最新技术方向 (SHAP 算法)

Shapley 博弈论分配:

03. 在已有“血氧=96%”的子集 {C} 中加入心率

血氧正常时，叠加心率 115，模型预测风险为 32%。此时心率的边际贡献为： $32\% - 20\% = +12\%$

最新技术方向 (SHAP 算法)

Shapley 博弈论分配:

04. 在全集 {B, C} 中加入心率

已知血压低、血氧正常时，加入心率 115，模型输出最终风险 70%。而未加入心率前预测为 52%。此时心率边际贡献为： $70\% - 52\% = +18\%$

最新技术方向 (SHAP 算法)

Shapley 博弈论分配:

05. 数学加权平均

依据 Shapley 核心公式对上述边际增量进行博弈论加权组合排列:

算法计算各特征加入不同“指标子集”时的全排列边际增量: $\text{Phi}_i(x) = \text{sum}(\text{Weight}_S * [f_x(S + \{i\}) - f_x(S)])$

$\text{Weight}_S = |S|! * (|F| - |S| - 1)! / |F|!$ 代表组合权重系数

最新技术方向 (SHAP 算法)

Shapley 博弈论分配:

05. 心率边际计算示例

加入空集 None: 风险从 20% -> 35% (边际 +15%)

加入血压集 {血压}: 低血压叠加高心率, 风险从 45% -> 65% (边际 +20%)

最终博弈加权平均得到各指标贡献: $\Phi_{\text{血压}} = +36\%$, $\Phi_{\text{心率}} = +16\%$, $\Phi_{\text{血氧}} = -2\%$

最新技术方向（SHAP 算法）

结论：病人之所以被判定为 70% 的高危心衰，血压偏低（90 mmHg）是最大推手，贡献了足足 36% 的风险涨幅；心率偏快贡献了 16% 的涨幅；而正常的血氧值稍微挽回了 2% 的安全额度。医生据此可迅速制定“优先纠正低血压、同时控制心率”的精准临床干预策略。

最新技术方向

最新趋势 |

大语言模型的 机械可解释性

**注意力机制分析：追踪多头
注意力（MHA）在复杂文本
中的上下文关联**

**机械可解释性 (Mechanistic
XAI)：逆向工程 LLM，将权重
矩阵还原为清晰的算法电路**

**探测任务 (Probing)：测试模
型隐藏层中是否包含特定的底
层语义或事实表征**

最新技术方向

大语言模型的机械可解释性：

场景：

输入文本：“苹果发布了最新款的智能手机。”

**核心挑战：模型如何精准判定这里的“苹果”是指
（科技公司）而不是（水果）？**

最新技术方向

注意力机制分析：

在计算“苹果”这个词的 head_i 时，softmax 权重矩阵在“智能手机”、“发布”这两个上下文 Token 上展现出极高的归一化高亮数值。数学上证明：模型是通过关联“智能手机”来锁定“苹果”的语义

最新技术方向

注意力机制分析：

核心功能：追踪多头注意力（MHA）在复杂文本中的上下文关联，通过将注意力权重矩阵可视化为热力图，揭示 Token 之间的依赖深度

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h) * \\ W_{\text{Ohead}_i} = \text{softmax}((Q * W_{i_Q} * (K * W_{i_K})^T) / \text{sqrt}(d_k)) * \\ V * W_{i_V}$$

Q, K, V：输入矩阵，分别代表查询（Query）、键（Key）和值（Value）

$W_{i_Q}, W_{i_K}, W_{i_V}$ ：第 i 个注意力头的线性投影权重矩阵

$\text{sqrt}(d_k)$ ：缩放因子，用于防止点积结果过大导致 Softmax 梯度消失

softmax：按行归一化计算上下文关联权重

最新技术方向

机械可解释性：

通过路径消融技术，强行关闭了第 5 层的第 3 个注意力头。结果发现模型瞬间无法识别“苹果”是公司了。这成功逆向定位出该特定组件属于专门处理“商品-品牌因果连接”的算法电路

最新技术方向

机械可解释性：

核心功能： 对大模型进行“逆向工程”，将庞大复杂的权重矩阵拆解还原为人类清晰可读的残差流与“算法电路”

$$\begin{aligned} x_L &= x_0 + \text{sum}(\text{MHA}_l(x_{l-1})) + \text{sum}(\text{MLP}_l(x_{l-1}))\text{Effect}(H_l, h) \\ &= f(x_0) - f_{\text{ablate}}(H_l, h)(x_0) \end{aligned}$$

x_0, x_L ：初始 Token 嵌入向量与经过 L 层 Transformer 块叠加后的最终残差流（Residual Stream）向量

$\text{MHA}_l, \text{MLP}_l$ ：第 l 层注意力层与感知机层对残差流增量更新的非线性修正

f_{ablate} ：路径消融/剪痕技术，通过将目标注意力头 H_l, h 的输出强行置零，根据模型输出的差值因果效应，逆向定位特定的算法功能电路

最新技术方向

探测任务：

保持大模型全部参数冻结，提取处理到“苹果”时的隐藏层状态向量 h_{i_l} 。在上面挂载一个微型的线性分类器 (W_{probe_l})，去预测【实体分类】。结果探针分类准确率高达 99% 并输出“组织机构”，在数学上证明大模型该层内部已经隐式凝聚了“苹果是公司”的高维事实表征

最新技术方向

探测任务：

核心功能：测试和检验大模型内部隐藏层状态（Hidden States）中是否真正隐式包含了特定的底层语义或事实表征

$$y_{\text{pred}} = \text{argmax}(\text{softmax}(W_{\text{probe}_l} * h_{i_l} + b_{\text{probe}_l}))$$

h_{i_l} ：大模型第 l 层内部生成的隐藏状态向量，在探测阶段其全部参数保持完全冻结（Frozen）

$W_{\text{probe}_l}, b_{\text{probe}_l}$ ：挂载在隐藏层之上的微型线性探测器（Linear Probe）的可训练权重与偏置

因果推理与反事实解释

反事实解释：回答“输入需要发生什么最小改变，才能改变当前的预测结果”

因果图模型：结合因果发现，将黑盒决策路径映射为因果链条

鲁棒性提升：利用因果关系过滤虚假相关性，避免模型“走捷径”

最新技术方向

因果推理与反事实解释：

场景：

输入数据：某用户申请信用卡，其数据为（收入=低，既往逾期=0次，近期申卡次数=10次）

黑盒输出：拒绝批卡（风险判定为高）

最新技术方向

反事实解释：

算法计算后给该用户输出了一条反事实路径：x_prime = （收入=低，既往逾期=0次，近期申卡次数=2次）

解释：只要你将近期的申卡次数从 10 次降到 2 次（最小改变），系统就会自动从‘拒绝’变为‘同意’。”

最新技术方向

因果图模型：

通过统计学因果发现，算法画出了一条因果链：[近期申卡频繁(10次)] -> 触发[急需资金心理] -> 导致[未来违约概率高]

解释：它向审计人员证明，模型之所以拒绝他，不是因为特征间的随机巧合，而是内部建立了一条符合金融逻辑的因果信任链条

最新技术方向

鲁棒性提升：

如果原始数据中恰好存在“使用某特定小众浏览器的人违约率高”的虚假相关性，普通黑盒模型会以此作为“捷径”去无故拒绝用户

解释：引入因果惩罚项（Penalty）后，系统识别出“浏览器种类”与“违约”没有因果因果链。模型被强制剔除该特征，确保了即使换了数据集，系统的预测依然稳定、公正且鲁棒

04

主要应用场景

主要应用场景

应用场景 I

智慧医疗与临床决策支持

病灶多模态解释：在癌症或罕见病筛查中，通过显著图精准标注病灶病变区域

诊疗路径可溯源：与深度学习预测结合，给出基于特定生理指标异常的因果链条解释

医疗事故合规：为复杂手术或用药推荐提供可追溯的算法依据，明确人机协同中的法律与伦理责任

主要应用场景

应用场景 II

数字金融与可信风险控制

信贷与风控黑盒解构：在个人信用评估或大额贷款审批中，利用 SHAP 值的正负贡献度，清晰告知用户被拒绝的动态特征原因（如负债比过高）

反洗钱异常检测：通过图神经网络（GNN）的可解释性技术，勾勒出异常资金流转的拓扑路径，辅助风控专家研判

主要应用场景

应用场景 III

自动驾驶与端到端安全控制

长尾（Corner Cases）故障追溯：
当自动驾驶发生诡异误判或事故时，利用逆向工程和事后解释，定位是由于传感器噪声还是特征对齐失效导致的决策崩溃

人机接管信任重塑：通过语言或图形界面，向驾驶员实时反馈系统“看”到了什么以及“准备”怎么做，大幅提升智能座舱的人机协同安全性

总结

针对深度学习的黑盒危机，可解释人工智能技术形成了内在透明模型与事后解释两大路径（LIME/SHAP）。当前前沿正向 LLM 机械可解释性与因果推理迈进。目前，XAI 已成为医疗、金融、自动驾驶等高风险行业安全合规的硬性准入标准，未来将在性能、隐私与对抗安全的平衡中构建可信 AI

谢谢聆听

报告人：王浩权

指导老师：向广利 教授