

【切换至第 1 页】各位老师、同学们，大家上午好！我是报告人王浩权，在指导老师向广利教授的指导下，今天我为大家带来的报告主题是《可解释人工智能：最新技术方向与主要应用场景》。

【切换至第 2 页】本次报告我将分为四个部分来进行阐述：首先是技术背景，接着探讨可学习理论，随后重点介绍最新的技术方向，最后分享其在主要应用场景中的落地实践。

二、技术背景(第3-4页)

【切换至第 3 页】首先，我们进入第一部分：技术背景。

【切换至第 4 页】当前，深度学习中普遍存在的“黑盒”模型，在安全性、公平性以及合规性上都面临着巨大的挑战。我们之所以需要“可解释人工智能(XAI)”，核心原因有三点：

- 第一，我们要解释模型为什么会犯错，从而提高模型的稳定性；
- 第二，我们需要检查模型的决策是否依赖了不恰当的特征，确保其公平性；
- 第三，在法律法规层面，现在的法规已经赋予了用户获得自动化决策解释的法定权利。欧盟的 GDPR 第22条也是全球可解释性立法的标杆，它严格限制了完全脱离人工干预的自动化决策，并赋予了公众要求人工干预和获得算法合理解释的权利

三、可学习理论(第5-11页)

【切换至第 5 页】接下来，我们来看第二部分：可解释性的“可学习理论”。

【切换至第 6 页】在理论层面，目前主要有三大支撑：一是心智理论(ToM)，研究模型如何匹配人类的认知与理解习惯；二是信息瓶颈理论，通过量化特征的压缩与保留，寻找解释的最优解；三是可解释性度量，基于保真度、稀疏性和鲁棒性建立数学评估指标。

【切换至第 7 页】首先来看心智理论(ToM)。它的核心目标是最小化机器与人类之间的认知距离。从公式上来看，我们要让黑盒模型对原始数据的机器内部预测逻辑，与人类专家在看到解释线索后、在自身心智中建立的理解概率分布，两者之间的距离达到最小，从而让机器的解释真正符合人类的思维习惯。

【切换至第 8 页】其次是信息瓶颈理论。我们通过损失函数来平衡信息压缩度与预测相关性。公式中的 $I(X;Z)$ 代表输入与解释变量之间的互信息，这个数值越小，说明信息压缩度越高、解释越精简。我们的目标是在提炼出核心解释变量的同时，尽可能保留对目标标签的预测能力。

【切换至第 9 页】在可解释性度量方面，我们三个重要指标。第一个是局部保真度。它用来统计在局部邻域内，到底有多少个样本的预测被成功复刻。我们通过对比原黑盒模型和可解释代理模型(比如 LIME 训练的线性模型)对扰动样本输出的预测概率，来评估代理模型的拟合程度。

【切换至第 10 页】第二个指标是稀疏性。稀疏性用来统计特征权重矩阵中，数值不等于零的特征个数。只有权重不为零的特征，才是真正对最终决策起到作用的“核心有效特征”。非零元素越少，解释就越聚焦、越稀疏。

【切换至第 11 页】第三个指标是鲁棒性或稳定性。我们在扰动样本与原始样本的距离限制在极小阈值 ϵ 的前提下，去计算输入发生微观物理变化后，解释结论本身改变了多少。这个比值极大值越低，说明模型的解释越稳定，不会因为一点点噪声就发生剧烈抖动。

四、最新技术方向(第12-40页)

【切换至第 12 页】 下面我将介绍第三部分，也是本次报告的重点：最新技术方向。

【切换至第 13 页】 在基础算法层面，目前最著名的两大流派是 **LIME** 算法和 **SHAP** 算法。**LIME** 算法的核心思想是在预测样本周围进行局部扰动，训练一个线性代理模型来进行局部解释；而 **SHAP** 算法则基于合作博弈论的沙普利值，实现了特征贡献度的唯一公理化分配。

【切换至第 14 页】 为了让大家更直观地理解，我们来看一个 **LIME** 算法的具体信贷审批场景。假设有一位24岁的申请人，月入6500元，信用卡负债4.5万元，历史逾期0次。基于 XGBoost 的黑盒模型给出的预测结果是：拒绝贷款，高风险概率高达85%。那么，模型为什么拒绝他？

【切换至第 15 页】 **LIME** 算法的操作分为四个步骤。第一步是扰动采样。我们在申请人特征周围加入高斯噪声，生成5000个虚拟的局部样本。比如样本1特征很接近，黑盒预测同样是高风险；而样本2因为月入激增，黑盒预测变成了低风险。

【切换至第 16 页】 第二步是邻域加权。我们计算这5000个扰动样本与原申请人的欧氏距离，距离越近，相似度权重就越大。比如刚刚特征接近的样本1权重高达0.95，而月入激增的样本2由于距离太远，权重极低，只有0.05。

【切换至第 17 页】 第三步是代理拟合。我们以黑盒预测输出为标签，以接近度为样本加权，训练一个简单的线性回归器。通过限制特征数量，只保留最核心的2到3个特征，从而在局部近似那个非线性的黑盒模型。

【切换至第 18 页】 第四步是系数提取。求解出局部线性回归系数后，我们得到了决策方程：风险变化等于正的 45% 乘以负债，加上 15% 乘以年龄，减去 5% 乘以收入。

【切换至第 19 页】 由此，我们得出明确的结论：该用户被拒贷的首要原因是信用卡负债过高（拉高了45%的风险）；其次是年龄较小（拉高了15%的风险）；月收入虽然有微弱的正面拉低风险作用，但完全无法抵消高负债带来的冲击。这就把黑盒给解构了。

【切换至第 20 页】 接下来我们看 **SHAP** 算法的应用场景：多模态神经网络实时预测急性心力衰竭风险。病人当前心率115偏高，血压90/60偏低，血氧96%正常。全院的基准期望风险是20%，但模型最终给出的高危预测值是70%。这高出来的50%风险该如何分配？**SHAP** 算法利用博弈论分配，分步计算边际贡献：

【切换至第 21 页】

- 第一步，在没有任何基础特征的空集时加入“心率=115”，预测风险从20%升至35%，心率的边际贡献是正的15%。【切换至第 22 页】
- 第二步，在已有“血压=90”的子集中叠加“心率=115”，由于低血压和高心率的双重异常，风险从45%激增至65%，此时心率的边际贡献是正的20%。【切换至第 23 页】
- 第三步，在已有“血氧=96%”的正常子集中加入心率，风险从20%升至32%，边际贡献是正的12%。【切换至第 24 页】
- 第四步，在已有血压和血氧的全集中加入心率，模型输出最终的70%，未加入前是52%，此时心率的边际贡献是正的18%。

【切换至第 25 页】 第五步是数学加权平均。算法依据 Shapley 核心公式，对上述在不同指标子集下的全排列边际增量进行博弈论加权组合，计算出每个特征的最终贡献度。

【切换至第 26 页】 经过最终的博弈加权平均，我们得到了各个指标的精准贡献：血压贡献了正的36%，心率贡献了正的16%，而血氧挽回了负的2%。

【切换至第 27 页】 由此得出的结论是：病人被判定为70%高危，最大推手是血压偏低（贡献了36%的涨幅），其次是心率偏快（贡献了16%）。医生据此可以迅速制定出“优先纠正低血压、同时控制心率”的精准临床干预策略，真正实现了大模型的辅助医疗决策。

【切换至第 28 页】 除了基础算法，目前最前沿的趋势之一是大语言模型的机械可解释性（**Mechanistic XAI**）。它主要包含三大技术：注意力机制分析、机械可解释性逆向工程、以及探测任务。

【切换至第 29 页】 我们来看一个具体的大模型场景。输入文本：“苹果发布了最新款的智能手机。” 核心挑战在于：模型是如何精准判定这里的“苹果”是指科技公司而不是水果的？

【切换至第 30 页】 首先，通过注意力机制分析发现，在计算“苹果”这个词的注意力时，Softmax 权重矩阵在“智能手机”和“发布”这两个上下文 Token 上展现出了极高的数值。这在数学上证明了模型是通过关联上下文来锁定语义的。

【切换至第 31 页】 从公式上看，它追踪的是多头注意力（MHA）在复杂文本中的上下文关联，通过将注意力权重矩阵可视化为热力图，清晰地揭示了 Token 之间的依赖深度。

【切换至第 32 页】 第二种方法是深度的机械可解释性研究。研究人员通过“路径消融技术”，强行关闭了模型第5层的第3个注意力头，结果发现模型瞬间无法识别“苹果”是公司了。这成功地逆向定位出，该特定组件属于专门处理“商品-品牌因果连接”的算法电路。

【切换至第 33 页】 这种方法就像对大模型进行“逆向工程”，通过路径消融或剪痕技术将目标注意力头强行置零，根据模型输出的差值因果效应，把复杂的残差流拆解还原为人类清晰可读的算法功能电路。

【切换至第 34 页】 第三种方法是探测任务（**Probing**）。我们保持大模型的全部参数冻结，提取它处理到“苹果”时的隐藏层状态向量，并在上面挂载一个微型的线性分类器作为探针。结果探针的分类准确率高达99%并输出“组织机构”，在数学上证明了大模型内部隐藏层已经隐式凝聚了“苹果是公司”的高维事实表征。

【切换至第 35 页】 它的数学原理很简单，就是利用完全冻结的隐藏状态向量，通过挂载一个可训练的微型线性探测器，来测试和检验大模型内部是否真正包含特定的底层语义或事实表征。

【切换至第 36 页】 前沿趋势之二，是因果推理与反事实解释。它包括反事实解释、因果图模型以及利用因果关系提升模型鲁棒性。

【切换至第 37 页】 我们同样来看一个场景：某用户申请信用卡，数据为收入低、既往逾期0次、但近期申卡次数高达10次，黑盒模型最终拒绝批卡。

【切换至第 38 页】 此时，反事实解释算法会给用户输出一条反事实路径：只要你将近期的申卡次数从10次降到2次（做出最小改变），系统就会自动从“拒绝”变为“同意”。它直接回答了“输入需要发生什么最小改变，才能逆转当前预测结果”的问题。

【切换至第 39 页】而因果图模型则通过统计学因果发现，画出了一条因果链：近期申卡频繁触发了急需资金心理，从而导致未来违约风险高。这向审计人员证明了模型内部建立的是符合金融逻辑的因果信任链条，而不是随机的巧合。

【切换至第 40 页】更重要的是，因果推理能带来鲁棒性的提升。如果数据中存在“使用某特定小众浏览器的人违约率高”这种虚假相关性，普通模型会走捷径盲目拒绝用户。但引入因果惩罚项后，系统识别出浏览器与违约没有因果链，强制剔除该特征，从而确保了系统在换了数据集后依然稳定、公正且鲁棒。

五、主要应用场景与总结(第41-46页)

【切换至第 41 页】最后，我们来看看第四部分：主要应用场景。

【切换至第 42 页】首先是智慧医疗与临床决策支持。在癌症等筛查中，XAI 可以通过显著图精准标注病灶区域；结合深度学习提供基于生理指标异常的因果链条追溯；并在医疗事故合规中，明确人机协同的法律与伦理责任。

【切换至第 43 页】其次是数字金融与可信风险控制。在个人信贷审批中，利用 SHAP 值清晰告知用户被拒的动态原因；在反洗钱异常检测中，通过图神经网络(GNN)的可解释性技术勾勒出异常资金流转的拓扑路径，辅助专家研判。

【切换至第 44 页】再者是自动驾驶与端到端安全控制。当自动驾驶发生长尾故障或事故时，利用逆向工程和事后解释定位是传感器噪声还是特征失效；同时在智能座舱中，通过语言或图形实时向驾驶员反馈系统的意图，重塑人机接管的信任与安全性。

【切换至第 45 页】

总结来看，针对深度学习的黑盒危机，可解释人工智能目前已经形成了内在透明模型与事后解释两大成熟路径。当前的前沿正向着大模型的机械可解释性与因果推理大步迈进。可以说，XAI 已经成为医疗、金融、自动驾驶等高风险行业安全合规的硬性准入标准。未来，它将在性能、隐私与对抗安全的平衡中，构建起真正可信的 AI。

【切换至第 46 页】以上就是我报告的全部内容。谢谢聆听！请各位老师、同学批评指正。