

物联网应用中的可解释人工智能研究综述

赵小阳¹, 许新征^{2*}, 李仲年²

(1. 中国矿业大学徐海学院, 江苏 徐州 221008; 2. 中国矿业大学 计算机科学与技术学院, 江苏 徐州 221116)

(* 通信作者电子邮箱 xuxinzhi@163.com)

摘要:在物联网(IoT)时代,人工智能(AI)与IoT的结合已经成为推动技术发展和应用创新的重要趋势。随着设备连接数量的指数级增长,提升终端用户对智能系统的信任度变得尤为关键。可解释人工智能(XAI)指能提供它们的决策过程和结果解释的AI系统。XAI的出现推动了AI技术的发展,并增强了用户对AI系统的信任。因此,对IoT应用中的XAI研究进行综述。首先,介绍IoT和XAI的相关背景及意义;其次,介绍XAI的定义及关键技术;接着,介绍传统AI驱动的IoT应用的最新进展和XAI驱动的IoT应用的最新进展;最后,对XAI在IoT应用中的未来发展方向和相关挑战分别进行总结和展望。

关键词:可解释人工智能;深度学习;物联网;智慧医疗;智慧工业;智慧城市

中图分类号:TP181 **文献标志码:**A

Research review on explainable artificial intelligence in internet of things applications

ZHAO Xiaoyang¹, XU Xinzhen^{2*}, LI Zhongnian²

(1. Xuhai College, China University of Mining and Technology, Xuzhou Jiangsu 221008, China;

2. School of Computer Science and Technology, China University of Mining and Technology, Xuzhou Jiangsu 221116, China)

Abstract: In the era of Internet of Things (IoT), the integration of Artificial Intelligence (AI) and IoT has become a significant trend driving technological advancements and application innovations. With the exponential growth in the number of connected devices, enhancing end-users' trust in intelligent systems has become especially critical. Explainable Artificial Intelligence (XAI) refers to AI systems capable of providing their decision-making processes and outcome explanations. The emergence of XAI has propelled the development of AI technology and increased users' trust in AI systems. Therefore, a research review on XAI in IoT applications was performed. Firstly, the background and significance of IoT and XAI were discussed. Secondly, the definition and key technologies of XAI were presented. Thirdly, the recent progress in traditional AI-driven IoT applications as well as XAI-driven IoT applications were introduced. Finally, the future development directions of XAI in IoT applications were prospected and the associated challenges were summarized.

Key words: Explainable Artificial Intelligence (XAI); deep learning; Internet of Things (IoT); smart healthcare; smart industry; smart city

0 引言

物联网(Internet of Things, IoT)经过十多年的快速发展和广泛应用,从智能城市到多媒体应用,通过在物联网环境中部署各种类型的传感器和设备产生了海量需要分析的数据。人工智能(Artificial Intelligence, AI),特别是深度学习,已经在包括计算机视觉、语音识别和自然语言处理等诸多领域取得显著成就。将AI引入物联网,基于深度学习的解决方案^[1-3]在解决海量数据分析、入侵检测和预测等物联网问题方面表现良好,意味着人工智能物联网(Artificial intelligence Internet of Things, AIoT)的时代已经到来。

然而,AIoT面临着两个主要的挑战:超参数设置和AI模型的黑盒特性。超参数设置:深度学习模型具有多种可调的超参数,如迭代数、激活函数、损失函数、批次数等。为了实现深度学习模型的良好性能,需要为不同的超参数找到最优

值^[4-6]。AI模型的黑盒特性:深度学习体系结构是基于黑盒的模型。这些黑盒模型是通过训练算法直接从数据中创建的,这意味着用户,包括模型的开发者,对模型如何产生预测结果的具体因素是不够明确的,这会降低用户对于基于深度模型的系统的信任度,进而限制它们在医疗保健、自动驾驶和刑事司法等高风险行业的应用。

基于上述挑战,研究者们提出了一种解决方案,即可解释人工智能(Explainable Artificial Intelligence, XAI)^[7-9]。因XAI具有高透明、可信赖、可解释的系统开发等诸多优点,吸引了众多应用领域的关注,在医疗保健^[10-13]、金融财管^[14-16]、交通管理^[17-19]、军事法律^[20-21]和国防安全^[22-23]等多个领域XAI能保证更可信的可持续发展。因此,在未来XAI系统可能会逐渐替代传统的AI系统。

在物联网系统中使用XAI,可以安全地处理物联网设备中的隐私和数据保护,并明确AI模型如何作出决策。将XAI

收稿日期:2024-07-03;修回日期:2024-10-17;录用日期:2024-10-18。 基金项目:国家自然科学基金资助项目(61976217,62306320)。

作者简介:赵小阳(1999—),女,宁夏吴忠人,硕士,CCF会员,主要研究方向:深度神经网络的可解释性、物联网; 许新征(1980—),男,安徽宿州人,教授,博士生导师,博士,CCF高级会员,主要研究方向:机器学习、数据挖掘、医学图像处理; 李仲年(1990—),男,江苏徐州人,讲师,博士,CCF会员,主要研究方向:机器学习、数据挖掘、医学图像处理。

扩展到物联网相关应用领域,可以使学术和工业研究进入一个新的维度,为医疗保健、军事国防、工业制造等物联网应用中的道德问题和模型决策透明度的维护提供可能。

随着 XAI 技术和 IoT 技术的进步,在物联网应用中,以 AI 驱动的工程将逐渐向 XAI 驱动模式转变。为了便于研究人员针对物联网应用中的 XAI 技术的研究,本文对 IoT 结合 XAI 的相关研究进行回顾和总结。

1 XAI 关键技术

1.1 XAI

XAI 是一种帮助人类理解机器/深度学习算法如何产生输出的方法。它有助于量化模型的正确性、公平性和透明性,并最终实现 AI 辅助决策。XAI 对于用户在使用 AI 模型时的信任和信心至关重要。此外,AI 的可解释性使开发者

能以负责任的方式进行 AI 开发^[24]。2018 年,Lipton^[25]总结了可解释性的 3 层含义,分别是:可模拟性(simulatability)、可分解性(decomposability)和算法透明性(algorithmic transparency)。可模拟性指整个模型层面可解释或者透明,例如线性分类器;可分解性指可以通过理解模型的每一个组件的作用来理解整个模型的作用,例如决策树;算法透明性指理解模型的训练和动态行为。与可理解的或者透明的 XAI 模型相对的就被称为黑盒 AI 模型,图 1 给出了传统的黑盒 AI 系统和 XAI 系统之间的差异^[26]。

在传统的 AI 系统中,终端用户无法解释模型的学习过程,AI 模型看起来就像一个不透明的黑盒子。与传统的黑盒 AI 不同,XAI 系统通过开发新的机器学习过程和可解释的模型,为终端用户持续提供模型学习过程的透明度,并根据训练数据作出决策^[26]。




图 1 黑盒 AI 系统和 XAI 系统的工作机制^[26]

Fig. 1 Working mechanisms of black-box AI systems and XAI systems^[26]

1.2 关键技术

XAI 研究成果众多,分类方式多样,有基于解释层次的局部解释和全局解释;基于输出类型的视觉解释和文本解释;基于模型依赖性的模型无关方法和模型特定方法;基于技术方法的特征分析、规则提取和代理模型等。本节从两个方向对 XAI 的关键技术进行整理:一种是对已经训练好的模型进行解释;另一种是从头设计可解释的模型。这种分类方式也被称为事后可解释分析和事前可解释建模^[27]。

1.2.1 事后可解释分析

事后可解释分析通常是借助模型额外的辅助信息对训练好的神经网络模型节点激活总体趋势的统计,是为了详述黑盒模型内部功能或决策原因而采取的一些行动。激活最大化方法是一种典型的基于理想样本的事后可解释分析方法,具体方法是,针对任意神经元 i , 寻找一个最优输入样本 $\mathbf{x}^*$, 使神经元的激活函数 $a_i(\mathbf{x}^*)$ 最大化,即:

$$\mathbf{x}^* = \arg \max_{\mathbf{x}} (a_i(\mathbf{x}) - R_\theta(\mathbf{x})) \quad (1)$$

其中: $R_\theta(\mathbf{x})$ 为正则项。不同类别的神经元对应的最优输入样本称为该类别的类模型可视化结果,文献[28]中通过展示神经网络中不同类别的类模型可视化结果证实了算法的正确性。

局部可解释性模型诊断解释(Local Interpretable Model-agnostic Explanation, LIME)框架^[29]采用代理模型方式,通过配置一个可解释的简单线性模型 g 模拟原始模型 f 决策。具体方法是,假设存在待解释模型 $f: \mathbf{R}^d \rightarrow \mathbf{R}$, 在输入样本 $\mathbf{x}$ 的附近采样得到样本 $\mathbf{z} \in \{0, 1\}^d$, 用 $\pi_{\mathbf{x}}(\mathbf{z})$ 衡量 $\mathbf{z}$ 与 $\mathbf{x}$ 的相似度,

用 $\mathcal{L}(f, g, \pi_{\mathbf{x}})$ 衡量由 $\pi_{\mathbf{x}}$ 定义下的 g 逼近 f 时的不忠实程度。LIME 的目标是在可解释模型集合 G 中寻找一个线性模型 g , 使:

$$\xi(\mathbf{x}) = \arg \min_{g \in G} \mathcal{L}(f, g, \pi_{\mathbf{x}}) + \Omega(g) \quad (2)$$

其中: $\Omega(g)$ 用于衡量解释 $g \in G$ 的复杂性。图 2 为 LIME 的原理图,图 2 中粗十字表示需要解释的实例 $\mathbf{x}$, 原始黑盒模型 f 的决策函数表示为蓝色/粉色。LIME 通过对实例 $\mathbf{x}$ 进行采样,用线性模型 g (图 2 中的直虚线) 近似解释模型 f , 即通过 $\mathbf{x}$ 附近的采样点 (图 2 中粗十字附近的圆点) 解释 $\mathbf{x}$ 。




图 2 LIME 原理图

Fig. 2 Principle graph of LIME

另外,还有基于合作博弈论的 Shapley 值方法^[30],通过计算每个特征对模型输出的平均边际贡献来解释模型决策。逐层传播相关性(Layer-wise Relevance Propagation, LRP)方法^[31]通过逐层反向传播模型的激活,将输出的决策值分配回输入特征,以解释每个输入特征的贡献。梯度加权类激活映射 (Gradient-weighted Class Activation Mapping,

Grad-CAM)^[32]通过计算每个输入像素对输出的贡献,即计算梯度加权的激活图生成输入图像的热力图,以解释模型决策。Skater 开源工具^[33]旨在根据局部和全局预测结果解释 XAI 模型的学习特征,以构建透明的 XAI 模型,该模型可以应用于社会中的大多数用例。

1.2.2 事前可解释建模

事前可解释建模是从头设计可以自解释的固有可解释神经网络,自解释模型在应用的同时为用户直接提供模型输出的决策原因,无需添加额外的信息。例如,可解释的深度模型 TesNet^[34]通过构造类别(C 个类)子空间分离的透明潜在空间 S_b ,并约束类内概念 $B^{(c)}$ 彼此正交,实现类别感知且解纠缠的透明化神经网络。具体为,TesNet 主要由卷积层 $f(\cdot)$ 、具有基础概念 B 的透明子空间层 $S_b(\cdot)$ 和分类器 $h(\cdot)$ 3部分组成。给定一张输入图像 x_i ,由 $f(\cdot)$ 得到它的特征图 Z_i ;接着,将 Z_i 投射到 $S_b(\cdot)$, $S_b(\cdot)$ 中的每个基本单元 $S_{b_j}(\cdot)$ (每个类一个子空间, C 个类就是 C 个子空间)将计算 Z_i 上所有 1×1 小块到第 j 个基础概念(每个子空间由 M 个基础概念贯穿。对于所有类,共有 $M \times C$ 个基础概念)之间的投射距离,并使用全局最大池化将投射距离压缩为一个值,即

$$S_{b_j}(Z_i) = \max_{P \in \text{patches}(Z_i)} P^T b_j \quad (3)$$

最后,将所有基本单元 $S_{b_j}(\cdot)$ 上的投射距离作为分类器 $h(\cdot)$ 的输入,作出最终预测。TesNet 的优化目标主要包括类内概念的正交性约束、类感知子空间的分离、高级别图像块成组以及识别的交叉熵损失4项。

此外,SENN(Self-Explaining Neural Network)^[35]是通过将可解释性嵌入神经网络中,使每个预测都可以用少量关键特征和解释性系数来表示。Chen等^[36]和Donnelly等^[37]设计基于案例推理的神经网络结构来剖析图像,通过类别典型特征解释模型推理。类别可解释的神经聚类 TELL(Terpretable nEural cLustering)网络^[38]将 k 均值目标重新表述为神经层,实现了算法透明化。Zhu等^[39]基于物理模型,根据雾的生成原理,构建端到端的神经网络模型,使模型中的各个模块都有清晰的物理意义。

可解释模型的开发者通常需要解释模型的内部工作原理,通过关联模型的输出与其输入,以解答模型审查员对于理解模型决策过程的要求^[40]。基于模型中特征的贡献,可解释性提供关于模型输入的基础数据和模型的解释。图3是与 XAI 模型相关的术语之间的关系。




图3 XAI模型相关术语的关系

Fig. 3 Relationship of terms related to XAI model

2 传统AI驱动下的IoT应用

在当下IoT时代,随着物联网设备数量的急剧增长,数以

亿计的传感器和设备持续从环境中收集数据,并通过互联网将这些数据传输至云端,实现设备间的互联互通。然而,传输大量异构数据,从海量数据中感知并分析复杂的环境信息,并作出明智的推理决策是很困难的^[41]。基于AI的深度学习技术在包括计算机视觉、自然语言处理和语音识别等领域中取得了成功,将AI引入IoT,可进一步增强数据分析能力,作出更明智的决策;进一步提高自动化水平,优化资源分配;进一步提升用户体验,根据用户行为和偏好提供个性化服务;进一步增强安全性等。本节从IoT感知、学习、推理以及行为4方面对AIoT具有代表性的研究成果进行简单梳理。

2.1 AIoT感知

感知,即通过各种传感器采集环境数据。将轻量级的深度神经网络^[42-43]部署到AIoT的边缘设备,已经是一种较为广泛的AIoT策略,利用轻量级深度神经网络模型参数更少、计算复杂度更低的优势,降低边缘设备成本。在许多使用视觉传感器的AIoT系统中,目标检测作为视频数据结构化的关键技术,从视频数据中提取并组织结构化的语义信息,实现在较低的传输、存储和计算成本下进行进一步的检索、统计和分析。行人、汽车、交通标志和车牌等特定类别物体的检测已经得到了广泛的研究^[44-46],这也进一步提升了交通、公共安全监控^[47-48]以及自动驾驶^[49-50]AIoT系统的感知能力。文本识别在现实场景中非常常见,例如交通标志、铭牌和信息板等,从场景图像中“读取”文本信息也是AIoT感知的一个重要任务,文本识别技术也是许多AIoT应用中的一种有用工具,例如用于教育的实时摄像机翻译^[51]、视障人士的阅读助手^[52]、光学字符识别用于自动文档分析^[53],以及用于定位和导航的存储铭牌识别等。另外,人脸识别^[54-55]、指纹识别^[56]、掌纹识别、虹膜识别等生物特征识别技术经过长期的研究和开发,已成为AIoT应用中的关键组成部分,为安全访问控制、个人身份认证、智能监控等场景提供了高度准确和可靠的解决方案。人体姿态估计^[57]、手势识别^[58]和动作识别^[59]也是AIoT应用中的关键技术,获取人体的运动和姿态信息,才能进一步实现对人类行为的智能理解和响应。除了视觉感知以外,语音作为最重要的非接触交互方式之一,自动语音识别在许多AIoT应用中非常重要,包括智能语音输入系统^[60]、自动语音转录系统^[61]、智能语音助手^[62]以及计算机辅助语音康复和语音教学^[63]等。表1总结了AIoT中与感知相关的主要应用以及对应的代表性数据集。

2.2 AIoT学习

由于现实世界的动态性和复杂性,在AIoT系统中采用固定的模型可能无法有效应对环境变化,并可能导致系统性能下降。因此,为AIoT系统赋予学习能力至关重要,可使AIoT系统通过持续学习和适应环境变化来优化其性能和功能。在机器学习中,描述了学习算法如何从数据中提取模式和知识,有不同的范式,常见的范式有监督学习(Supervised Learning, SL)、无监督学习(UnSupervised Learning, USL)、半监督学习(Semi-Supervised Learning, SSL)、迁移学习、领域适应、少/零样本学习、强化学习、联邦学习等。

在AIoT系统中,不同应用场景采用不同的学习范式,例如标注大规模数据可能昂贵且耗时,基于USL和SSL便可以通过大量传感器收集大规模未标记数据来持续改进AIoT系统中的模型^[64]。此外,通过集成多种异构传感器(如RGB/红

外/深度摄像头、激光雷达和麦克风等)所收集的多模态数据,可用于设计一系列基于跨模态的前置任务(如视听对应和自主运动)和基于自由语义标签的前置任务(如深度估计和语义分割),以实现自我监督学习^[65]。

表 1 AIoT 感知应用场景及代表性数据集
Tab. 1 AIoT perception application scenarios and representative datasets

感知类别	应用场景	代表性数据集
通用场景感知	图像识别	ImageNet、CIFAR10/100
	目标检测/追踪	COCO、MOT
	文本识别	LSVT
以人为主体的感知	人脸识别	FFHQ、YouTube Faces DB
	指纹识别	FVC2000
	姿态估计	COCO、MPII
	手势识别	DVS128
	动作识别	ActivityNet
听觉感知	语音识别	CHiME-3、VoxCeleb
	说话人识别	TIMIT APCSC、Common Voice
自然语言处理	机器翻译	TedTalks、WMT
多媒体分析	图像字幕	COCO、Flickr30k
	跨媒体检索	PKU XMediaNet
3D 感知	深度估计	KITTI、NYU Depth Dataset V2
	定位	KITTI
	地图构建	TUM Visual-Inertial

现实生活中的 AIoT 系统总会涉及许多相关联的任务,如视频监控中的目标检测与跟踪、语义分割等。在 AIoT 系统中,找到上述不同任务之间的迁移学习依赖关系,并利用这些先验知识学习更好的模型,对于 AIoT 学习具有实用价值^[66-67]。另外,将模型部署到新场景或新工作模式时,领域自适应能力对 AIoT 应用也很重要^[68-70]。

强化学习是与 SL、USL、SSL 并列的一种机器学习范式,基于环境的反馈而作出相应的行动,通过不断与环境的交互、试错,最终完成特定目的或者使整体行动收益最大化。强化学习不需要训练数据的标签,但需要每一步行动环境给予的反馈,是奖励还是惩罚,通过量化反馈,不断调整训练对象的行为。最近,结合深度学习强大表征能力的强化学习,即深度强化学习(Deep Reinforcement Learning, DRL)取得了快速的进展^[71],DRL 的出现使智能体能处理高维度的状态空间和动作空间。DRL 赋予事物与动态世界交互和适应的能力,已应用在许多 AIoT 系统中,例如智能交通中的自动驾驶^[72-73]、智能医疗中的机器人控制^[74]、智能教育中的课程推荐^[75]、智能电网中的负载调度^[76]、智能农业中的植物生长控制^[77],以及智能城市中的网络管理^[78]等。此外,DRL 可以集成到联邦学习框架中,用于用户的隐私保护学习^[79-80]。

表 2 各类心血管疾病预测分类模型的 AUC 值比较

单位: %

Tab. 2 Comparison of AUC values of various cardiovascular disease prediction classification models

unit: %

心血管疾病预测分类模型		AUC 值
传统机器学习算法驱动模型	基于自适应算法 AdaBoost	75.0
	结合朴素贝叶斯的多模态整合框架	79.9
	基于逻辑回归算法 LR 和带径向基函数的支持向量机算法 SVM	87.2
	基于监督学习的环境辅助生活预测模型	83.0
XAI 驱动模型		89.0

2.3 AIoT 推理

推理,是 AIoT 系统的核心能力之一,主要涉及运用知识图谱推理和因果推理技术,根据 AIoT 学习到的知识推理相关问题的答案或者进行患者诊断等操作。推理能力在众多 AIoT 应用场景中发挥着关键作用,例如在电子商务领域实现个性化推荐^[81],在智能工厂中构建数字孪生^[82],在智能电网中进行故障诊断^[83]、在智能医疗中辅助智能助手^[84],以及在智能安全领域支持安全驾驶^[85]等。此外,知识图谱推理和因果推理还可用于解决可解释问题,可进一步推动 XAI 在物联网系统中的应用,从而提升系统的透明度和信任度。

2.4 AIoT 行为

AIoT 系统中的行为主要包括主动探索未知事物的行为和被动响应环境变化的行为控制和交互两方面。控制指控制 AIoT 系统中的传感器和执行器,DRL 已被用于自主机器人控制,例如自动驾驶^[86]、移动服务机器人^[87]、公共交通中的主动摄像头。交互指 AIoT 系统以不同方式与人类或环境进行交互,例如智能家居中的问答系统和语音合成^[88-89]、人机交互中的模仿学习^[90]、多语言翻译^[91]等。

3 XAI 在 IoT 应用中的最新进展

近年来,通过智能传感设备感知各种环境数据,并引入智能边缘计算和边缘 AI 设备与物联网技术集成的 AIoT 系统已取得显著的成效^[92-94]。然而,边缘 AI 设备和强大的机器学习方法无法实现实时或近实时决策,且大多数机器学习模型高度依赖于训练数据集、预处理数据方法和微调非透明机器学习模型。当前数据驱动的方法无法理解和解释复杂的决策相关任务^[95]。用 XAI 取代基于 AI 的 IoT 系统可以提高物联网设备操作的透明度,为相关机器学习模型的决策过程提供更深入的洞察,增强 IoT 系统的可信程度以及保护隐私安全^[96-97]。AIoT 的主要应用场景包括智慧医疗、智能制造、工业物联网、自动驾驶、环境监测分析、智慧城市、智能家居等。考虑到篇幅原因,本章对主要的 AIoT 场景进行整合梳理,从智慧医疗、智慧工业、智慧城市 3 个综合 IoT 场景入手,介绍 XAI 在相关 IoT 用例上的最新进展。

3.1 智慧医疗

将 XAI 概念引入医疗物联网(Medical Internet of Things, IoMT),可以提高利用物联网数据预测健康信息的透明度和物联网数据的安全,提供值得信赖的医疗保健服务。文献[98]中提出了一种基于 XAI 的框架用于心血管疾病的预测,文中以 AUC 值为标准,比较采用传统机器学习算法的各类心血管疾病预测分类模型与 XAI 驱动模型的性能,对比结果如表 2^[98]所示。从表 2 可看出,基于 XAI 的分类模型可以进一步提高诊断的准确性和可靠性,得益于 XAI 能揭示 AI 模型的决策过程,可以帮助识别和纠正可能的错误,从而提高诊断的准确性。

文献[99]中设计并实现了一种基于物联网的医疗监测框架,该框架结合了深度学习方法和XAI技术,用于心脏病的检测和分类;文献[100]中研究了各种XAI框架在医疗健康中解释疾病检测和预测模型的应用;文献[101]中综述了在医学影像应用中使用的XAI技术;文献[102]中介绍了一种新的XAI评分系统,以更好地评估和实施医疗领域中的可解释解决方案。这些研究表明XAI在提高IoMT系统的透明度和信任度方面的潜力,有助于医务人员在疾病检测和预测中作出更准确和可靠的决策。图4展示了融合XAI的智慧医疗系统^[26]。




图4 融合XAI的智慧医疗系统^[26]

Fig. 4 Intelligent healthcare system integrating XAI^[26]

3.2 智慧工业

随着工业制造过程中互联系统的采用,工业制造也面临着越来越大的网络安全风险。因此,需要XAI的配合在智能制造中赋予工业物联网(Industrial Internet of Things, IIoT)数据的可信度,以实现智能制造过程的网络安全,增强隐私和安全功能。例如,文献[103]中使用网络物理-人类分析的方式加强人与机器之间的信任,增强对动态建模、认知预测和人与机器之间优化交互的信任。文献[104]中设计了一种专门服务于IIoT的可解释、高效且高精度的基于机器学习的入侵检测系统,称为E2I3DS。文献[105-106]利用XAI检测IIoT中的网络威胁,检测系统的决策过程透明且易于理解,有助于增强系统的信任度和可维护性。文献[107]开发了MCloud平台,用于在工业4.0环境中建立具有改进隐私功能和增强灵活性的安全节能的生产网络。文献[108]中开发了一种基于工业区块链的产品生命周期管理模型,用于交换安全的数据服务、安全的存储平台、分散的数据访问以及工业4.0兼容网络之间的互操作性。基于IIoT数据驱动的安全执法也适用于智能工厂断路器的生产^[109]。图5展示了XAI在工业4.0环境中起到的作用^[26],其中ERP(Enterprise Resource Planning)是企业资源规划、MES(Manufacturing Execution System)是制造执行系统、Process为生产流程。通过引入XAI技术,工业4.0和工业5.0可以加强智能制造业,形成一个具有弹性和动态生态系统的现代产业集群^[110]。

3.3 智慧城市

智能家居和智能楼宇是智慧城市的重要组成部分。在智能家居或智能楼宇中,设备通过互联网连接,可对家用电器

器进行远程监控和管理。智能家居技术又称家庭物联网(Home Internet of Things, IoHT),可为住户提供便利、安全、定期维护和节能控制。智能家居系统通过活动识别技术监控和理解居民的行为,以提供个性化的服务和自动化功能。然而,一般的活动识别算法通常是黑箱操作,用户无法理解系统如何得出结论,这可能导致信任缺失和接受度降低。文献[111]中开发和评估了一种可解释的活动识别框架,对智能家居(Human Activity Recognition, HAR)模型生成易于理解和偏好的自然语言解释。通过测试用户在同步远程监控和异步远程监控两种场景下对4类XAI模型以及没有解释的基础AI模型的感知结果的方式,测试用户感知准确性、感知解释充分性、感知信心3个指标的结果。测试者被要求使用李克特量表陈述,结果显示基于XAI模型的解释相较于没有解释的基础AI模型,“同意”率明显更高,详情参见文献[111]的图14~16。文献[111]中证实了基于XAI模型的智能家居系统能增强用户对智能家居HAR系统行为和决策过程的理解和信心。文献[112]中开发了一种名为DeXAR的可解释深度学习模型,用于基于传感器数据的智能家居活动识别。此外,随着智能家居系统的普及,出现了用户常常难以理解复杂的安全警告问题,导致他们忽视这些警告或无法采取有效的防范措施。文献[113]中探讨了可解释警告在智能家居环境中的应用及其对用户行为和安全性的影响。智能能源建筑系统通过数据驱动的方法进行能耗预测和异常检测,以提高能源效率和降低运营成本。为了提高用户的信任度和系统的透明性,文献[114]中开发和评估了一种XAI方法,用于智能能源建筑中的能耗预测和异常检测。




图5 XAI在工业4.0中的作用^[26]

Fig. 5 Role of XAI in Industry 4.0^[26]

计算机视觉在智慧城市中也有许多应用,例如自动驾驶中的目标检测,可避免碰撞、事故、减少交通流量、监控犯罪嫌疑人^[115]减少犯罪、抗击灾害等^[116-117]。上述应用均具有高度敏感性,一旦决策失误,公民的财产乃至生命安全都可能受到威胁。XAI可以通过分类结果的可解释性和合理性,解决智慧城市中基于计算机视觉应用的相关问题。具有计算机视觉功能的XAI可以更透明化地处理文本、图像和音频数据等多种异构数据^[118]。文献[119]中探讨并开发了一种参与式方法,结合XAI技术使市民能参与并理解智能城市系统的设计和运行。

另外,智慧交通也是智慧城市的一个重要应用领域,对于汽车行为的解释工作已经取得了一定的成果^[120-121]。通过各种传感器和数据分析技术,能对汽车的行驶轨迹、速度变化、驾驶习惯等方面进行监测和分析。文献[122]中提出一种名为InterFuser的可解释传感器融合转换器,充分融合来自多模态传感器的信息,实现了全面的场景理解。文献

[123-124]中分别通过分层模仿学习和利用潜在深度强化学习实现可解释的端到端自动驾驶。文献[125]中采用可解释的级联模糊神经网络从自然驾驶数据集的连续数据中提取规则,设计基于学习的变道决策框架,汽车能在不同驾驶场景下作出准确的变道行为决策,并提供决策规则。

现阶段,将XAI融入AIoT应用场景的相关研究众多,且已取得了颇为不错的进展。然而不同的AIoT应用场景有其特定的需求和侧重点,因此XAI的具体目标也会有所差异。例如,在智能家居场景中,更关注对家电控制决策的解释;而在工业自动化场景中,对设备故障预测和生产流程优化的解释更重要。图6总结了建立XAIoT系统,XAI的主要目标。实际应用中,需根据具体场景的需求来确定和调整XAI的目标。



图6 XAI在AIoT中的主要目标

Fig. 6 Main goals of XAI in AIoT

4 IoT应用中XAI的未来研究方向和挑战

目前在IoT实际应用场景中融入XAI技术还存在一定的滞后性,与XAI技术发展之间存在一定的差距,主要还是以将特定场景下原有AI系统改进为XAI系统的方式为主。因此,本章面向IoT应用,针对XAI可切入的研究方向展开阐述,并就XAIoT系统当前面临的问题进行简述,进而针对这些挑战提出可能的解决方向。

4.1 XAIoT研究方向

XAIoT研究方向主要有以下几个方面:

1) 边缘XAI结构。

随着IoT设备的激增以及连接至云服务的数据量的迅猛增长,网络带宽极有可能成为制约因素,进而导致超出预期的额外成本支出。为了解决IoT网络中的资源管理问题,文献[78]中提出了在边缘设备上实施机器学习和深度学习,即本文3.2节所述的AIoT感知。AIoT感知通常涉及多模态的数据,如传感器数据、图像、音频等。对于AIoT感知操作而言,公平、无偏见、可信赖和可解释的结果至关重要,而可靠和可信赖的人工智能算法可以实现这一点^[126]。因此,未来还需要进一步研究如何对多模态数据进行综合且有效的解释。边缘XAI能提供更好地理解 and 验证AI模型的机制及其决策过程的技术。通常情况下,一般的AI结构并不足以完全支持传授具备可解释特征的模型。因此,未来的研究需要深入探索特定的学习方法,以发展出适应性强的XAI架构,以弥补传统AI结构的不足。

2) XAI算法优化。

基于机器学习,尤其是深度学习,为AIoT系统赋予学习能力,使AIoT系统能不断学习及适应环境变化,从而提升其性能和功能。然而因深度学习模型的黑盒属性,需要对深度神经网络进行解释,以更好地了解网络、学习网络、总结网络

运行规律、了解神经网络错误决策的原因。同时可以为优化神经网络提供建议,从而为提升网络性能和设计更优秀的神经网络提供依据和方向。现阶段,XAI算法的优化主要从探索神经网络原理和优化神经网络结构两个方向进行^[127]。语义通信是IoT智能通信系统的一个重要发展方向,为了在信息的传输过程中提取见解(不仅传输数据,还有数据所包含的语义信息),需要设计高效的方法来优化IoT环境中的语义通信^[128-129]。将语义通信与XAI的融合,具有XAI能力的边缘设备用户可以实时监测通过解读语义信息作出的决策。基于深度学习的语义通信是提高传输效率的关键技术之一,文献[130]中通过探索神经网络原理,提出一种可解释方案,利用样例表示网络隐藏单元习得的语义信息。另外,在IoT实时性要求较高的场景中,如工业控制、智能交通等,实现对模型决策的实时解释也至关重要。因此,未来需要针对不同的AIoT应用场景,对XAI算法进行进一步的优化研究。

3) 面向6G的XAI。

迄今为止,无线通信领域的大量研究已经为6G服务奠定了基础,将地面、空中和海上通信发展到了新的维度。6G技术的发展,意味着物联网设备将需要处理更复杂的数据、实现更高级的智能决策,并且要求更高的数据传输速率、更低的延迟和更高的连接密度^[131-132]。因此,以下方向或将成为XAIoT的重要研究领域^[133-134]:面向6G低延迟、高可靠需求的XAI模型优化,需兼顾能源效率与动态环境适应性^[135];超高密度连接场景下每个设备的决策解释机制,以支撑资源分配优化和管理;针对6G多层架构与跨域协同特性,研究如何进行跨层跨域优化,实现决策过程的跨层可解释性,提升整体性能;针对6G物联网复杂的安全和隐私环境,开发可解释性技术,以应对复杂环境下的安全机制设计需求。

4.2 XAIoT面临的挑战

XAIoT面临的挑战主要有以下几个方面:

1) 计算资源限制。

在AI赋能的IoT解决方案中,大规模的设备和网络部署已经成为必然趋势,XAI技术的结合可以有效地应对这一问题。例如,一个能智能分配网络和设备资源的IoT框架,可以提供更高效率和更低的能耗;然而,由于IoT系统的分布式特性以及模型需要适应多样化场景,计算资源分配问题仍具有挑战性。因此,开发高灵活性、低复杂度的XAI模型,以节能的方式进一步提高IoT系统的可信性,是XAIoT的一个关键研究方向。

2) 数据隐私保护。

在XAIoT系统中,XAI模型通过从IoT设备中收集数据进行训练,并向决策者/用户提供理由/解释,在这个过程中,要确保不泄露敏感信息,保护用户隐私。鉴于目前IoT应用中的数据安全和网络安全方面的挑战仍然普遍存在,安全和隐私也是XAIoT系统需要考虑的主要问题。在XAIoT系统中,可以从赋予隐私和机密性的角度来研究防御攻击的机制以及扩展XAI方法的威胁模型使它反映真实世界环境^[136-137]两个方向开展研究,从而对IoT设备所收集的数据加以保护。

3) 模型复杂性。

XAIoT的AI模型的复杂度随性能的提升而增加,而模型自身的可解释性通常会随着复杂度的提高而减弱。在追求性能提升的同时,保持模型的可解释性成为一项挑战。在这

一过程中,当模型的性能与复杂性齐头并进时,解释工作变得困难,可解释能力的下降似乎难以避免^[138]。故而,有必要对如何简化和分解复杂模型的解释展开研究。鉴于平衡模型可解释性与模型性能间的关系,可以通过适度增加可解释算法的复杂程度,以实现算法复杂度高的模型的解释。

4)可扩展性。

可扩展性是评估系统性能的关键指标之一^[139]。在动态的XAIoT系统中,其功能的实现依赖于多样化的机器、多种AI算法和方法、海量传感数据以及大规模的IoT网络。为了确保这些组件之间的高效协作和网络节点以及AI方法的灵活性和响应性,XAI方法应具备出色的可扩展性。未来,XAI架构有望与响应式AI相结合,以增强XAIoT应用和系统的可扩展性^[140],从而满足不断变化的需求和挑战。

5)缺乏统一标准规范。

标准规范是描述一系列规则和条件的文件。目前对于可解释性的评估及实现方法方面,尚缺乏统一的标准和规范,为XAIoT系统制定高标准至关重要。统一的标准规范将有助于减少歧义,增强系统稳健性,促进对生活/工作环境的深入理解,推动更完善、先进的XAIoT系统的发展^[141-142],以及更迅速地获取充足的信息,从而作出明智的决策^[143]。此外,用户应当了解所在XAIoT系统中施行的各类标准和政策,以确保提供的解释能真正被用户理解和有效利用,缩小技术解释与人类认知之间的差距。

5 结语

本文针对IoT应用中的XAI的最新进展、未来趋势以及面临的挑战展开了详细研讨。首先,本文阐述了XAI的定义,强调了在IoT应用中引入XAI技术的必要性,并从事后可解释分析和事前可解释建模两个方向对XAI的关键技术进行了梳理。接着,本文从AIoT的感知、学习、推理和行为4个维度概述了当前AIoT领域的代表性工作。然后,本文以智慧医疗、智慧工业、智慧城市这3个综合IoT场景为切入点,介绍XAI在相关IoT用例上的最新进展。最后,本文探讨了XAIoT未来的研究方向和当前面临的挑战。当前XAIoT这一课题的研究尚处于相对初级的阶段,希望本文能助力读者了解该领域,为日后在该领域开展相关研究和实践提供参考和启发。

参考文献 (References)

- ABBASI J S, BASHIR F, QURESHI K N, et al. Deep learning-based feature extraction and optimizing pattern matching for intrusion detection using finite state machine [J]. *Computers and Electrical Engineering*, 2021, 92: No. 107094.
- JAN B, FARMAN H, KHAN M, et al. Deep learning in big data analytics: a comparative study [J]. *Computers and Electrical Engineering*, 2019, 75: 275-287.
- PRATES R M, CRUZ R, MAROTTA A P, et al. Insulator visual non-conformity detection in overhead power distribution lines using deep learning [J]. *Computers and Electrical Engineering*, 2019, 78: 343-355.
- BALAH A H M, SAIF M, TAMER A, ABDELHAY E H, et al. Hybrid deep learning and genetic algorithms approach (HMB-DLGAHA) for the early ultrasound diagnoses of breast cancer [J]. *Neural Computing and Applications*, 2022, 34(11): 8671-8695.
- KILICARSLAN S, CELIK M, SAHIN S, et al. Hybrid models based on genetic algorithm and deep learning algorithms for nutritional anemia disease classification [J]. *Biomedical Signal Processing and Control*, 2021, 63: No. 102231.
- PAN Y, YANG Y, LI W. A deep learning trained by genetic algorithm to improve the efficiency of path planning for data collection with multi-UAV [J]. *IEEE Access*, 2021, 9: 7994-8005.
- IVANOV S M, KADIKIS R, OZOLS K. Perturbation-based methods for explaining deep neural networks: a survey [J]. *Pattern Recognition Letters*, 2021, 150: 228-234.
- MOHSENI S, ZAREI N, RAGAN E D. A multidisciplinary survey and framework for design and evaluation of explainable AI systems [J]. *ACM Transactions on Interactive Intelligent Systems*, 2021, 11(3/4): No. 24.
- VASSILIADIS A, BASSILIADIS N, PATKOS T. Argumentation and explainable artificial intelligence: a survey [J]. *The Knowledge Engineering Review*, 2021, 36: No. e5.
- NAZAR M, ALAM M M, YAFI E, et al. A systematic review of human-computer interaction and explainable artificial intelligence in healthcare with artificial intelligence techniques [J]. *IEEE Access*, 2021, 9: 153316-153348.
- SRINIVASU P N, SANDHYA N, JHAVERI R H, et al. From blackbox to explainable AI in healthcare: existing tools and case studies [J/OL]. *Mobile Information Systems*, 2022 [2024-05-10]. <https://onlinelibrary.wiley.com/doi/10.1155/2022/8167821>.
- TJOA E, GUAN C. A survey on Explainable Artificial Intelligence (XAI): toward medical XAI [J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2021, 32(11): 4793-4813.
- JIMÉNEZ-LUNA J, GRISONI F, SCHNEIDER G. Drug discovery with explainable artificial intelligence [J]. *Nature Machine Intelligence*, 2020, 2(10): 573-584.
- KUTE D V, PRADHAN B, SHUKLA N, et al. Deep learning and explainable artificial intelligence techniques applied for detecting money laundering — a critical review [J]. *IEEE Access*, 2021, 9: 82300-82317.
- ZHOU L, SHI X, BAO Y. Explainable artificial intelligence for digital finance and consumption upgrading [J]. *Finance Research Letters*, 2023, 58(Pt C): No. 104489.
- SABHARWAL R, MIAH S J, WAMBA S F, et al. Extending application of explainable artificial intelligence for managers in financial organizations [EB/OL]. [2024-09-01]. <https://link.springer.com/content/pdf/10.1007/s10479-024-05825-9.pdf>.
- KOLEKAR S, GITE S, PRADHAN B, et al. Explainable AI in scene understanding for autonomous vehicles in unstructured traffic environments on Indian roads using the inception U-Net model with Grad-CAM visualization [J]. *Sensors*, 2022, 22(24): No. 9677.
- MANKODIYA H, OBAIDAT M S, GUPTA R, et al. XAI-AV: explainable artificial intelligence for trust management in autonomous vehicles [C]// *Proceedings of the 2021 International Conference on Communications, Computing, Cybersecurity, and Informatics*. Piscataway: IEEE, 2021: 1-5.
- ATAKISHIYEV S, SALAMEH M, YAO H, et al. Explainable artificial intelligence for autonomous driving: a comprehensive overview and field guide for future research directions [J]. *IEEE Access*, 2024, 12: 101603-101625.
- WARREN A, HILLAS A. Friend or frenemy? the role of trust in human-machine teaming and lethal autonomous weapons systems [J]. *Small Wars and Insurgencies*, 2020, 31(4): 822-850.
- DEEKS A. The judicial demand for explainable artificial intelligence [J]. *Columbia Law Review Association*, 2019, 119(7): 1829-1850.

- [22] ZOLANVARI M, YANG Z, KHAN K, et al. TRUST XAI: model-agnostic explanations for AI with a case study on IIoT security [J]. IEEE Internet of Things Journal, 2023, 10(4): 2967-2978.
- [23] GUNNING D, AHA D W. DARPA's Explainable Artificial Intelligence (XAI) program [J]. AI Magazine, 2019, 40(2): 44-58.
- [24] EHSAN U, WINTERSBERGER P, LIAO Q V, et al. Operationalizing human-centered perspectives in explainable AI [C]// Proceedings of the Extended Abstracts of the 2021 CHI Conference on Human Factors in Computing Systems. New York: ACM, 2021: No. 94.
- [25] LIPTON Z C. The mythos of model interpretability [J]. Communications of the ACM, 2018, 61(10): 36-43.
- [26] JAVED A R, AHMED W, PANDYA S, et al. A survey of explainable artificial intelligence for smart cities [J]. Electronics, 2023, 12(4): No. 1020.
- [27] FAN F L, XIONG J, LI M, et al. On interpretability of artificial neural networks: a survey [J]. IEEE Transactions on Radiation and Plasma Medical Sciences, 2021, 5(6): 741-760.
- [28] SIMONYAN K, VEDALDI A, ZISSERMAN A. Deep inside convolutional networks: visualising image classification models and saliency maps [EB/OL]. [2024-07-27]. <https://arxiv.org/pdf/1312.6034.pdf>.
- [29] ZAFAR M R, KHAN N. Deterministic local interpretable model-agnostic explanations for stable explainability [J]. Machine Learning and Knowledge Extraction, 2021, 3(3): 525-541.
- [30] ANTWARG L, MILLER R M, SHAPIRA B, et al. Explaining anomalies detected by autoencoders using shapley additive explanations [J]. Expert Systems with Applications, 2021, 186: No. 115736.
- [31] BACH S, BINDER A, MONTAVON G, et al. On pixel-wise explanations for non-linear classifier decisions by layer-wise relevance propagation [J]. PLoS ONE, 2015, 10(7): No. e0130140.
- [32] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-CAM: visual explanations from deep networks via gradient-based localization [C]// Proceedings of the 2017 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2017: 618-626.
- [33] MISHRA P. Model explainability and interpretability [M]// Practical explainable AI using python: artificial intelligence model explanations using Python-based libraries, extensions, and frameworks. Berkeley: Apress, 2022: 1-22.
- [34] WANG J, LIU H, WANG X, et al. Interpretable image recognition by constructing transparent embedding space [C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 875-884.
- [35] ALVAREZ-MELIS D, JAAKKOLA T S. Towards robust interpretability with self-explaining neural networks [C]// Proceedings of the 32nd International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2018: 7786-7795.
- [36] CHEN C, LI O, TAO C, et al. This looks like that: deep learning for interpretable image recognition [C]// Proceedings of the 33rd Conference on Advances in Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2019: 8930-8941.
- [37] DONNELLY J, BARNETT A J, CHEN C. Deformable ProtoPNet: an interpretable image classifier using deformable prototypes [C]// Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 10255-10265.
- [38] PENG X, LI Y, TSANG I W, et al. XAI beyond classification: interpretable neural clustering [J]. Journal of Machine Learning Research, 2022, 23: 1-28.
- [39] ZHU H, PENG X, CHANDRASEKHAR V, et al. DehazeGAN: when image dehazing meets differential programming [C]// Proceedings of the 27th International Joint Conference on Artificial Intelligence. California: ijcai.org, 2018: 1234-1240.
- [40] MESKE C, BUNDE E, SCHNEIDER J, et al. Explainable artificial intelligence: objectives, stakeholders, and future research opportunities [J]. Information Systems Management, 2022, 39(1): 53-63.
- [41] ZHANG J, TAO D. Empowering things with intelligence: a survey of the progress, challenges, and opportunities in artificial intelligence of things [J]. IEEE Internet of Things Journal, 2021, 8(10): 7789-7817.
- [42] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C]// Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 770-778.
- [43] HUANG G, LIU Z, VAN DER MAATEN L, et al. Densely connected convolutional networks [C]// Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2017: 2261-2269.
- [44] YANG K, LIU J, YANG D, et al. A novel efficient multi-view traffic-related object detection framework [C]// Proceedings of the 2023 IEEE International Conference on Acoustics, Speech and Signal Processing. Piscataway: IEEE, 2023: 1-5.
- [45] LI Z, YANG Z, GAO Y, et al. 6DoF-3D: efficient and accurate 3D object detection using six degrees-of-freedom for autonomous driving [J]. Expert Systems with Applications, 2024, 238(Pt F): No. 122319.
- [46] CHEN S, ZHANG Z, ZHANG L, et al. A semi-supervised learning framework combining CNN and multiscale transformer for traffic sign detection and recognition [J]. IEEE Internet of Things Journal, 2024, 11(11): 19500-19519.
- [47] ANTONANTE P, NILSEN H G, CARLONE L. Monitoring of perception systems: deterministic, probabilistic, and learning-based fault detection and identification [J]. Artificial Intelligence, 2023, 325: No. 103998.
- [48] CHENG C H, LUTTENBERGER M, YAN R. Runtime monitoring DNN-based perception: (via the lens of formal methods) [C]// Proceedings of the 2023 International Conference on Runtime Verification, LNCS 14245. Cham: Springer, 2023: 428-446.
- [49] CONG P, FENG H, LI S, et al. A visual detection algorithm for autonomous driving road environment perception [J]. Engineering Applications of Artificial Intelligence, 2024, 133(Pt A): No. 108034.
- [50] LU Y, JIANG B, LIU N, et al. CrossPrune: cooperative pruning for camera-LiDAR fused perception models of autonomous driving [J]. Knowledge-Based Systems, 2024, 289: No. 111522.
- [51] PARK H, LEE Y, KO J. Enabling real-time sign language translation on mobile platforms with on-board depth cameras [J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2021, 5(2): No. 77.
- [52] THAQI E, MANTAWY M O, KASNECI E. SARA: smart AI reading assistant for reading comprehension [C]// Proceedings of the 2024 Symposium on Eye Tracking Research and Applications. New York: ACM, 2024: No. 48.
- [53] LI M, LV T, CHEN J, et al. TrOCR: Transformer-based optical character recognition with pre-trained models [C]// Proceedings of

- the 37th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2023: 13094-13102.
- [54] CHI J, KIM ON C, ZHANG H, et al. A review of deep convolutional neural networks in mobile face recognition [J]. *International Journal of Interactive Mobile Technologies*, 2023, 17(23): 4-19.
- [55] PATTNAIK I, DEV A, MOHAPATRA A K. A face recognition taxonomy and review framework towards dimensionality, modality and feature quality [J]. *Engineering Applications of Artificial Intelligence*, 2023, 126(Pt C): No. 107056.
- [56] APPATI J K, NARTEY P K, YAOKUMAH W, et al. A systematic review of fingerprint recognition system development [J]. *International Journal of Software Science and Computational Intelligence*, 2022, 14(1): 1-17.
- [57] HELMSTETTER S, MATTHIESEN S. Human posture estimation: a systematic review on force-based methods — analyzing the differences in required expertise and result benefits for their utilization [J]. *Sensors*, 2023, 23(21): No. 8997.
- [58] TCHANTCHANE R, ZHOU H, ZHANG S, et al. A review of hand gesture recognition systems based on noninvasive wearable sensors [J]. *Advanced Intelligent Systems*, 2023, 5(10): No. 2300207.
- [59] SUN Z, KE Q, RAHMANI H, et al. Human action recognition from various data modalities: a review [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2023, 45(3): 3200-3225.
- [60] HE Y, SENG K P, ANG L M. Multimodal sensor-input architecture with deep learning for audio-visual speech recognition in wild [J]. *Sensors*, 2023, 23(4): No. 1834.
- [61] PARK S W, KIM D, JOE M C. Cotatron: transcription-guided speech encoder for any-to-many voice conversion without parallel data [C]// *Proceedings of the INTERSPEECH 2020*. [S. l.]: International Speech Communication Association, 2020: 4696-4700.
- [62] MUSTAFA H H, DARWISH N R, HEFNY H A. Automatic speech emotion recognition: a systematic literature review [J]. *International Journal of Speech Technology*, 2024, 27(1): 267-285.
- [63] VYAKARANAM A, MAUL T, RAMAYAH B. A review on speech emotion recognition for late deafened educators in online education [J]. *International Journal of Speech Technology*, 2024, 27(1): 29-52.
- [64] ZHANG Y, WANG J, CHEN B. Detecting false data injection attacks in smart grids: a semi-supervised deep learning approach [J]. *IEEE Transactions on Smart Grid*, 2021, 12(1): 623-634.
- [65] SAEED A, SALIM F D, OZCELEBI T, et al. Federated self-supervised learning of multi-sensor representations for embedded intelligence [J]. *IEEE Internet of Things Journal*, 2021, 8(2): 1030-1040.
- [66] D'INCECCO M, SQUARTINI S, ZHONG M. Transfer learning for non-intrusive load monitoring [J]. *IEEE Transactions on Smart Grid*, 2020, 11(2): 1419-1429.
- [67] BARGOTI S, UNDERWOOD J. Deep fruit detection in orchards [C]// *Proceedings of the 2017 IEEE International Conference on Robotics and Automation*. Piscataway: IEEE, 2017: 3626-3633.
- [68] WANG Q, GAO J, LIN W, et al. Learning from synthetic data for crowd counting in the wild [C]// *Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Piscataway: IEEE, 2019: 8190-8199.
- [69] GIUFFRIDA M V, DOBRESCU A, DOERNER P, et al. Leaf counting without annotations using adversarial unsupervised domain adaptation [C]// *Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*. Piscataway: IEEE, 2019: 2590-2599.
- [70] ZHANG Z, WANG Y, LIU S. Cross-domain person re-identification using Dual Generation Learning in camera sensor networks [J]. *Ad Hoc Networks*, 2020, 97: No. 102019.
- [71] ARULKUMARAN K, DEISENROTH M P, BRUNDAGE M, et al. Deep reinforcement learning: a brief survey [J]. *IEEE Signal Processing Magazine*, 2017, 34(6): 26-38.
- [72] KARALAKOU A, TROULLINOS D, CHALKIADAKIS G, et al. Deep reinforcement learning reward function design for autonomous driving in lane-free traffic [J]. *Systems*, 2023, 11(3): No. 134.
- [73] UDUGAMA B. Review of deep reinforcement learning for autonomous driving [EB/OL]. [2024-02-03]. <https://arxiv.org/pdf/2302.06370.pdf>.
- [74] THANANJEYAN B, GARG A, KRISHNAN S, et al. Multilateral surgical pattern cutting in 2D orthotropic gauze with deep reinforcement learning policies for tensioning [C]// *Proceedings of the 2017 IEEE International Conference on Robotics and Automation*. Piscataway: IEEE, 2017: 2371-2378.
- [75] ZHANG J, HAO B, CHEN B, et al. Hierarchical reinforcement learning for course recommendation in MOOCs [C]// *Proceedings of the 33rd AAAI Conference on Artificial Intelligence*. Palo Alto: AAAI Press, 2019: 435-442.
- [76] CHUNG H M, MAHARJAN S, ZHANG Y, et al. Distributed deep reinforcement learning for intelligent load scheduling in residential smart grids [J]. *IEEE Transactions on Industrial Informatics*, 2021, 17(4): 2752-2763.
- [77] BINAS J, LUGINBUEHL L, BENGIO Y. Reinforcement learning for sustainable agriculture [EB/OL]. [2024-02-03]. <https://s3.us-east-1.amazonaws.com/climate-change-ai/papers/icml2019/32/paper.pdf>.
- [78] HUSSAIN F, HASSAN S A, HUSSAIN R, et al. Machine learning for resource management in cellular and IoT networks: potentials, current solutions, and open challenges [J]. *IEEE Communications Surveys and Tutorials*, 2020, 22(2): 1251-1275.
- [79] CHU K F, GUO W. Federated reinforcement learning for consumers privacy protection in mobility-as-a-service [C]// *Proceedings of the IEEE 26th International Conference on Intelligent Transportation Systems*. Piscataway: IEEE, 2023: 4840-4846.
- [80] ZHENG J, LI K, MHAISEN N, et al. Exploring deep-reinforcement-learning-assisted federated learning for online resource allocation in privacy-preserving EdgeIoT [J]. *IEEE Internet of Things Journal*, 2022, 9(21): 21099-21110.
- [81] SINHA S, RAKHRA M. AI driven e-commerce product recommendation [C]// *Proceedings of the 6th International Conference on Contemporary Computing and Informatics*. Piscataway: IEEE, 2023: 13-16.
- [82] LONGO F, NICOLETTI L, PADOVANO A. Ubiquitous knowledge empowers the Smart Factory: the impacts of a Service-oriented Digital Twin on enterprises' performance [J]. *Annual Reviews in Control*, 2019, 47: 221-236.
- [83] WANG Q, MAO Z, WANG B, et al. Knowledge graph embedding: a survey of approaches and applications [J]. *IEEE Transactions on Knowledge and Data Engineering*, 2017, 29(12): 2724-2743.
- [84] CHEN Y, KUANG J, CHENG D, et al. AgriKG: an agricultural knowledge graph and its applications [C]// *Proceedings of the*

- 2019 International Conference on Database Systems for Advanced Applications, LNCS 11448. Cham: Springer, 2019: 533-537.
- [85] KONG W, LIN W, BABILONI F, et al. Investigating driver fatigue versus alertness using the granger causality network [J]. *Sensors*, 2015, 15(8): 19181-19198.
- [86] LIANG X, LIU Y, CHEN T, et al. Federated transfer reinforcement learning for autonomous driving [M]// RAZAVI-FAR R, WANG B, TAYLOR M E, et al. Federated and transfer learning, ALO 27. Cham: Springer, 2023: 357-371.
- [87] ASGHARIAN P, PANCHEA A M, FERLAND F. A review on the use of mobile service robots in elderly care [J]. *Robotics*, 2022, 11(6): No. 127.
- [88] BANERJEE A, DALAL R, MITTAL S, et al. Generating digital twin models using knowledge graphs for industrial production lines [C]// Proceedings of the 2017 International ACM Web Science Conference. New York: ACM, 2017: 425-430.
- [89] ARIK S Ö, CHRZANOWSKI M, COATES A, et al. Deep Voice: real-time neural text-to-speech [C]// Proceedings of the 34th International Conference on Machine Learning. New York: JMLR. org, 2017: 195-204.
- [90] ZHANG T, MCCARTHY Z, JOW O, et al. Deep imitation learning for complex manipulation tasks from virtual reality teleoperation [C]// Proceedings of the 2018 IEEE International Conference on Robotics and Automation. Piscataway: IEEE, 2018: 5628-5635.
- [91] ANGELOV K, BRINGERT B, RANTA A. Speech-enabled hybrid multilingual translation for mobile devices [C]// Proceedings of the Demonstrations at the 14th Conference of the European Chapter of the Association for Computational Linguistics. Stroudsburg: ACL, 2014: 41-44.
- [92] CIRILLO F, GÓMEZ D, DIEZ L, et al. Smart city IoT services creation through large-scale collaboration [J]. *IEEE Internet of Things Journal*, 2020, 7(6): 5267-5275.
- [93] KIMOTHI S, THAPLIYAL A, SINGH R, et al. Comprehensive database creation for potential fish zones using IoT and ML with assimilation of geospatial techniques [J]. *Sustainability*, 2023, 15(2): No. 1062.
- [94] KIRIMTAT A, KREJCAR O, KERTESZ A, et al. Future trends and current state of smart city concepts: a survey [J]. *IEEE Access*, 2020, 8: 86448-86467.
- [95] GAI K, GUO J, ZHU L, et al. Blockchain meets cloud computing: a survey [J]. *IEEE Communications Surveys and Tutorials*, 2020, 22(3): 2009-2030.
- [96] SICARI S, RIZZARDI A, GRIECO L A, et al. Security, privacy and trust in Internet of Things: the road ahead [J]. *Computer Networks*, 2015, 76: 146-164.
- [97] CHEN I R, BAO F, GUO J. Trust-based service management for social Internet of Things systems [J]. *IEEE Transactions on Dependable and Secure Computing*, 2016, 13(6): 684-696.
- [98] GULERIA P, SRINIVASU P N, AHMED S, et al. XAI framework for cardiovascular disease prediction using classification techniques [J]. *Electronics*, 2022, 11(24): No. 4086.
- [99] MANSOOR J S, SUBRAMANIAM K. Healthcare monitoring-based IoT framework for heart disease detection and classification [J]. *Journal of Angiotherapy*, 2024, 8(3): 1-11.
- [100] YU H Q, ALABA A, EZIEFUNA E. Evaluation of integrated XAI frameworks for explaining disease prediction models in healthcare [C]// Proceedings of the 2023 International Workshop on Internet of Things of Big Data for Healthcare. Cham: Springer, 2024: 14-28.
- [101] CHADDAD A, PENG J, XU J, et al. Survey of explainable AI techniques in healthcare [J]. *Sensors*, 2023, 23(2): No. 634.
- [102] SHEU R K, PARDESHI M S. A survey on medical eXplainable AI (XAI): recent progress, explainability approach, human interaction and scoring system [J]. *Sensors*, 2022, 22(20): No. 8068.
- [103] JIAO J R, ZHOU F, GEBRAEEL N Z, et al. Towards augmenting cyber-physical-human collaborative cognition for human automation interaction in complex manufacturing and operational environments [J]. *International Journal of Production Research*, 2020, 58(16): 5089-5111.
- [104] ALANI M M. An explainable efficient flow-based Industrial IoT intrusion detection system [J]. *Computers and Electrical Engineering*, 2023, 108: No. 108732.
- [105] LIU Y, LI S. Hybrid cyber threats detection using explainable AI in Industrial IoT [C]// Proceedings of the 2023 International Conference on Human-Centered Cognitive Systems. Piscataway: IEEE, 2023: 1-6.
- [106] KHAN I A, MOUSTAFA N, PI D, et al. A new explainable deep learning framework for cyber threat discovery in industrial IoT networks [J]. *IEEE Internet of Things Journal*, 2022, 9(13): 11604-11613.
- [107] LU Y, PENG T, XU X. Energy-efficient cyber-physical production network: architecture and technologies [J]. *Computers and Industrial Engineering*, 2019, 129: 56-66.
- [108] LIU X L, WANG W M, GUO H, et al. Industrial blockchain based framework for product lifecycle management in industry 4.0 [J]. *Robotics and Computer-Integrated Manufacturing*, 2020, 63: No. 101897.
- [109] CHEN G, WANG P, FENG B, et al. The framework design of smart factory in discrete manufacturing industry based on cyber-physical system [J]. *International Journal of Computer Integrated Manufacturing*, 2020, 33(1): 79-101.
- [110] JAGATHEESAPERUMAL S K, RAHOUTI M, AHMAD K, et al. The duo of artificial intelligence and big data for industry 4.0: review of applications, techniques, challenges and future research directions [J]. *IEEE Internet of Things Journal*, 2022, 9(5): 12861-12885.
- [111] DAS D, NISHIMURA Y, VIVEK R P, et al. Explainable activity recognition for smart home systems [J]. *ACM Transactions on Interactive Intelligent Systems*, 2023, 13(2): No. 7.
- [112] ARROTTA L, CIVITARESE G, BETTINI C. DeXAR: deep explainable sensor-based activity recognition in smart-home environments [J]. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 2022, 6(1): No. 1.
- [113] MARTONE A, CENA F, GENA C, et al. Securing the smart home environment: an experiment on the impact of explainable warnings [C]// Proceedings of the 2024 International Conference on Advanced Visual Interfaces. New York: ACM, 2024: No. 72.
- [114] PRABHU H, VALDI J, ARJUNAN P. Explainable AI for energy prediction and anomaly detection in smart energy buildings [C]// Proceedings of the 10th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation. New York: ACM, 2023: 472-475.
- [115] ALAZAB M, BROADHURST R. Spam and criminal activity [J]. *Trends and Issues in Crime and Criminal Justice*, 2016(526): 1-20.
- [116] SHORFUZZAMAN M, HOSSAIN M S, ALHAMID M F. Towards the sustainable development of smart cities through mass video surveillance: a response to the COVID-19 pandemic [J].

- Sustainable Cities and Society, 2021, 64: No. 102582.
- [117] JAVED A R, JALIL Z, ZEHR A W, et al. A comprehensive survey on digital video forensics: taxonomy, challenges and future directions [J]. *Engineering Applications of Artificial Intelligence*, 2021, 106: No. 104456.
- [118] HAMZA A, JAVED A R R, IQBAL F, et al. Deepfake audio detection via MFCC features using machine learning [J]. *IEEE Access*, 2022, 10: 134018-134028.
- [119] GUPTA S. Mapping the smart city: participatory approaches to XAI [C]// *Proceedings of the 2023 ACM Designing Interactive Systems Conference*. New York: ACM, 2023: 1-6.
- [120] MORI K, FUKUI H, MURASE T, et al. Visual explanation by attention branch network for end-to-end learning-based self-driving [C]// *Proceedings of the 2019 IEEE Intelligent Vehicles Symposium*. Piscataway: IEEE, 2019: 1577-1582.
- [121] HASPIEL J, DU N, MEYERSON J, et al. Explanations and expectations: trust building in automated vehicles [C]// *Proceedings of the 2018 ACM/IEEE International Conference on Human-Robot Interaction*. New York: ACM, 2018: 119-120.
- [122] SHAO H, WANG L, CHEN R, et al. Safety-enhanced autonomous driving using interpretable sensor fusion Transformer [C]// *Proceedings of the 6th Conference on Robot Learning*. New York: JMLR.org, 2023: 726-737.
- [123] CHEN J, LI S E, TOMIZUKA M. Interpretable end-to-end urban autonomous driving with latent deep reinforcement learning [J]. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(6): 5068-5078.
- [124] TENG S, CHEN L, AI Y, et al. Hierarchical interpretable imitation learning for end-to-end autonomous driving [J]. *IEEE Transactions on Intelligent Vehicles*, 2023, 8(1): 673-683.
- [125] WANG H, CHEN Y, YU H, et al. Social cascade FNN: an interpretable learning-based decision-making framework for autonomous driving in lane changing scenarios [C]// *Proceedings of the IEEE 26th International Conference on Intelligent Transportation Systems*. Piscataway: IEEE, 2023: 3519-3526.
- [126] RAWAT D. Secure and trustworthy machine learning/artificial intelligence for multi-domain operations [C]// *Proceedings of the SPIE 11746, Artificial Intelligence and Machine Learning for Multi-Domain Operations Applications III*. Bellingham: SPIE, 2021: No. 1174609.
- [127] 窦慧, 张凌茗, 韩峰, 等. 卷积神经网络的可解释性研究综述 [J]. *软件学报*, 2024, 35(1): 159-184. (DOU H, ZHANG L M, HAN F, et al. Survey on convolutional neural network interpretability [J]. *Journal of Software*, 2024, 35(1): 159-184.)
- [128] GÜNDÜZ D, QIN Z, AGUERRI I E, et al. Guest editorial special issue on beyond transmitting bits: context, semantics, and task-oriented communications [J]. *IEEE Journal on Selected Areas in Communications*, 2023, 41(1): 1-4.
- [129] XU W, YANG Z, NG D W K, et al. Edge learning for B5G networks with distributed signal processing: semantic communication, edge computing, and wireless sensing [J]. *IEEE Journal of Selected Topics in Signal Processing*, 2023, 17(1): 9-39.
- [130] BAU D, ZHOU B, KHOSLA A, et al. Network dissection: quantifying interpretability of deep visual representations [C]// *Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition*. Piscataway: IEEE, 2017: 3319-3327.
- [131] NGUYEN D C, DING M, PATHIRANA P N, et al. 6G Internet of Things: a comprehensive survey [J]. *IEEE Internet of Things Journal*, 2022, 9(1): 359-383.
- [132] JAWAD A T, MAALOUL R, CHAARI L. A comprehensive survey on 6G and beyond: enabling technologies, opportunities of machine learning and challenges [J]. *Computer Networks*, 2023, 237: No. 110085.
- [133] WANG S, QURESHI M A, MIRALLES-PECHUÁN L, et al. Applications of explainable AI for 6G: technical aspects, use cases, and research challenges [EB/OL]. [2024-03-01]. <https://arxiv.org/pdf/2112.04698.pdf>.
- [134] SIDDIQUI M U A, QAMAR F, KAZMI S H A, et al. A study on multi-antenna and pertinent technologies with AI/ML approaches for B5G/6G networks [J]. *Electronics*, 2022, 12(1): No. 189.
- [135] ZHANG L, QAMAR F, LIAQAT M, et al. Toward efficient 6G IoT networks: a perspective on resource optimization strategies, challenges, and future directions [J]. *IEEE Access*, 2024, 12: 76606-76633.
- [136] BRADBURY M, JHUMKA A, WATSON T, et al. Threat-modeling-guided trust-based task offloading for resource-constrained Internet of Things [J]. *ACM Transactions on Sensor Networks*, 2022, 18(2): No. 29.
- [137] DE SILVA L P, NASCIMENTO B S, DIAS R A M P, et al. A comprehensive approach for applying threat modeling to Internet of Things systems [C]// *Proceedings of the IEEE 8th World Forum on Internet of Things*. Piscataway: IEEE, 2022: 1-6.
- [138] GAO J, WANG X, WANG Y, et al. Explainable recommendation through attentive multi-view learning [C]// *Proceedings of the 33rd AAAI Conference on Artificial Intelligence*. Palo Alto: AAAI Press, 2019: 3622-3629.
- [139] DAS A, RAD P. Opportunities and challenges in eXplainable Artificial Intelligence (XAI): a survey [EB/OL]. [2024-03-05]. <https://arxiv.org/pdf/2006.11371.pdf>.
- [140] KHAMPARIA A, GUPTA D, KHANNA A, et al. Biomedical data analysis and processing using explainable (XAI) and Responsive Artificial Intelligence (RAI), ISRL 222 [M]. Singapore: Springer, 2022.
- [141] AL-HILO A, SAMIR M, ASSI C, et al. UAV-assisted content delivery in intelligent transportation systems-joint trajectory planning and cache management [J]. *IEEE Transactions on Intelligent Transportation Systems*, 2021, 22(8): 5155-5167.
- [142] GUPTA B B, GAURAV A, MARÍN E C, et al. Novel graph-based machine learning technique to secure smart vehicles in intelligent transportation systems [J]. *IEEE Transactions on Intelligent Transportation Systems*, 2023, 24(8): 8483-8491.
- [143] SAMIR M, ASSI C, SHARAFEDDINE S, et al. Age of information aware trajectory planning of UAVs in intelligent transportation systems: a deep learning approach [J]. *IEEE Transactions on Vehicular Technology*, 2020, 69(11): 12382-12395.

This work is partially supported by National Natural Science Foundation of China (61976217, 62306320).

ZHAO Xiaoyang, born in 1999, M. S. Her research interests include interpretability of deep neural networks, internet of things.

XU Xinzhen, born in 1980, Ph. D., professor. His research interests include machine learning, data mining, medical image processing.

LI Zhongnian, born in 1990, Ph. D., lecturer. His research interests include machine learning, data mining, medical image processing.